

Segmentación de Clientes Mayoristas

Aprendizaje no supervisado para decisiones comerciales

Federico Morán y Juan Barboza

Trabajo Práctico Final - Aprendizaje No Supervisado

Pregunta

¿Qué grupos de clientes emergen a partir de su patrón de gasto anual?

- ▶ No hay etiqueta de segmento.
- ▶ La cartera mezcla Horeca y Retail.
- ▶ Buscamos segmentos **interpretables y accionables**.

Idea central: convertir patrones de compra en grupos útiles para logística, precios, retención y venta cruzada.

Dataset: atributos y validación externa


- ▶ **Wholesale Customers** - UCI. 440 clientes mayoristas.
- ▶ Se agrupa *solo* con las 6 variables de gasto anual: Fresh, Milk, Grocery, Frozen, Detergents_Paper, Delicassen.

Validación externa (no son atributos)

Channel (Horeca / Retail): pseudo-etiqueta para las métricas ARI y NMI.


Region (Lisboa / Oporto / otra): se inspecciona en t-SNE para descartar estructura geográfica.

Se reservan *fuera* del entrenamiento: usarlas como atributo haría circular la validación.



Señal EDA: Retail concentra más Grocery, Milk y Detergents_Paper; Horeca pesa más en Fresh y Frozen. Anticipa que la estructura dominante se alinearía con el canal.

Método: pipeline simple y comparable



Modelos	Evaluación
▶ K-Means como referencia. ▶ Agglomerative Clustering. ▶ Gaussian Mixture Models. ▶ Deep Embedded Clustering.	▶ Interna: Silhouette, Davies-Bouldin, Calinski-Harabasz. ▶ Externa: Channel como pseudo-etiqueta (ARI, NMI). ▶ Outliers conservados: son clientes reales.

Tres modelos más allá del baseline

Agglomerative

Jerárquico. Cada cliente inicia como un grupo; se fusionan los más cercanos. Enlace **Ward**: minimiza la varianza intra-grupo.

Elección: dendrograma + grilla de linkage $\Rightarrow k=3$.

Aporta: jerarquía interpretable; no exige grupos esféricos.

Gaussian Mixture

Probabilístico. Mezcla de k gaussianas (EM); cada cliente recibe una **probabilidad** de pertenencia (asignación blanda).

Elección: BIC sobre covarianza $\times k \Rightarrow$ full, $k=3$.

Aporta: cuantifica la incertidumbre $\rightarrow$ clientes fronterizos.

Deep Embedded Clustering

Deep clustering. Un autoencoder aprende una **representación latente** y una capa de agrupamiento se optimiza junto al encoder (KL).

Elección: grilla $d_{\text{lat}} \times k$, métricas internas.

Aporta: captura no-linealidad; pensado para alta dimensión.

K-Means queda como *baseline* de referencia.

Resultados: estructura recuperada sin etiquetas


Método	Silhouette	ARI canal	NMI canal
K-Means (k=2)	0.290	0.514	0.445
Ward (k=3)	0.255	0.549	0.409
GMM (k=3)	0.239	0.431	0.379
DEC (k=2)	0.285	0.546	0.457

Lectura

- ▶ Todos los métodos encuentran estructura real.
- ▶ La estructura se alinea con canal, pero no se reduce solo a canal.
- ▶ **Ward k=3** ofrece la partición más útil para negocio.

La decisión no se toma por una única métrica: se combina calidad numérica, tamaños de grupos e interpretabilidad.


Visualización t-SNE: qué ven los modelos



Dos regiones dominantes que coinciden con **Channel**, unidas por una zona de transición sin frontera nítida: eso explica las *silhouettes moderadas*.

El panel de **Region** no muestra patrón espacial: la estructura es **conductual, no geográfica**. Los métodos coinciden salvo el 3.^{er} grupo de Ward.

Insight de negocio: tres segmentos accionables




Segmentos Ward k=3 (n=440)

- ▶ **0 - Frescos / Horeca** (262): prioridad en cadena de frío y frecuencia de reparto.
- ▶ **1 - Reposición bajo volumen / mixto** (53): candidato a desarrollo de cuenta y venta cruzada.
- ▶ **2 - Reposición gran volumen / Retail** (125): foco en retención y condiciones comerciales.

Conclusión: el clustering transforma gasto histórico en segmentos comerciales interpretables.


Anexo – DEC: cómo funciona el deep clustering



- **Fase 1 (pre-entrenamiento):** el autoencoder comprime y reconstruye el gasto $\Rightarrow$ una representación latente z que preserva la información relevante.
- **Fase 2 (ajuste fino conjunto):** centroides inicializados con K-Means sobre z ; se optimizan encoder y centroides minimizando $KL(P \parallel Q)$ entre las asignaciones blandas q y una distribución objetivo P que las agudiza.

~2000 parámetros, full-batch y determinista; converge en segundos en CPU. Implementación en PyTorch siguiendo Xie et al. (2016).

Anexo: dendrograma de Ward



Lectura: el corte marcado produce tres grupos, que luego se interpretan como segmentos comerciales accionables.